

# Machine learning techniques for flow-based intrusion detection systems



Axel Faes: Bachelorthesis

# Onderwerp

Intrusie detectie

Classificeren/detectie van onverwacht netwerkgedrag

Extern en intern

IP Flows

Geaggregeerd vanuit packet data

specifiek bedoeld voor high traffic systems

vereist geen in-depth knowledge van het netwerk

Hoe kan flow data gebruikt worden in een IDS?

Welke types anomalie kunnen we automatisch detecteren ?

---

# Onderwerp

machine learning technieken

Algoritmes ‘leren’ zelf zonder regeltjes expliciet te programmeren

7 verschillende algoritmes

In hoeverre zijn machine learning technieken inzetbaar voor anomaly detection?

Kunnen we een IDS maken dat out-of-the-box een aanvaardbare ‘hit rate’ biedt ?

Zijn dergelijke technieken bruikbaar in real-life condities ?

---

# Werking:

## Stap 1

Aanleren van het model  
via subset van een  
learning data set

## Stap 2


Validatie met gekende  
test-data uit learning data  
set

## Stap 3

Testing met real-world  
gelabelde data

## Stap 4

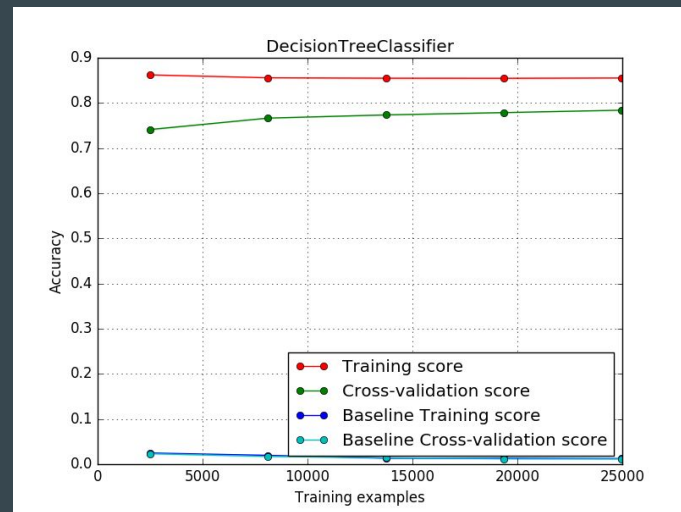
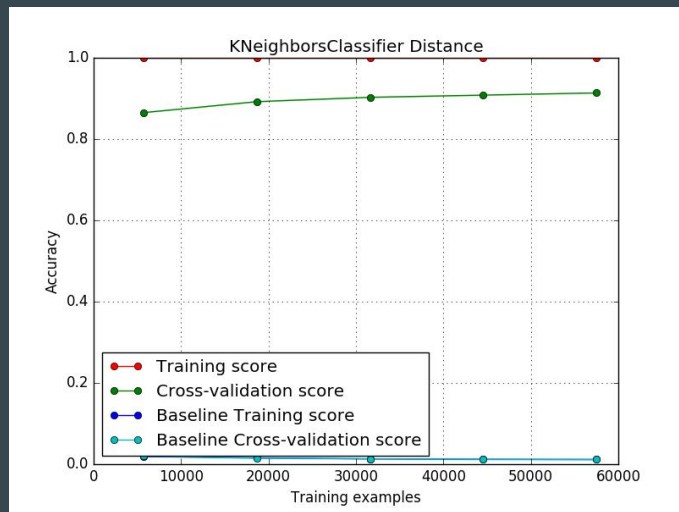
Validatie met  
ongelabelde  
real-world data



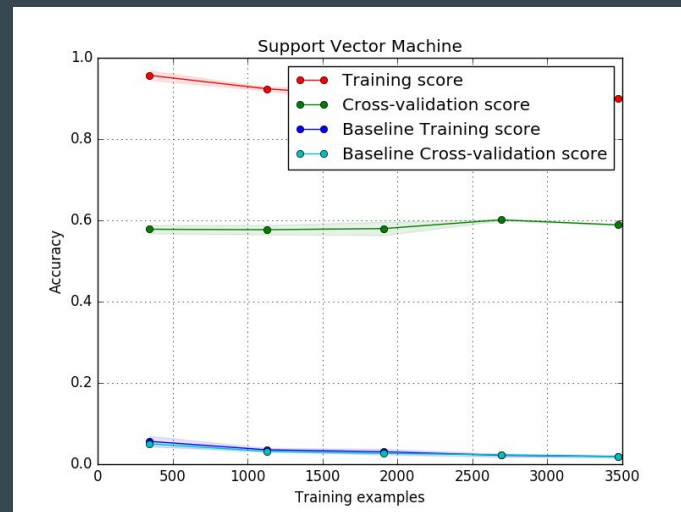
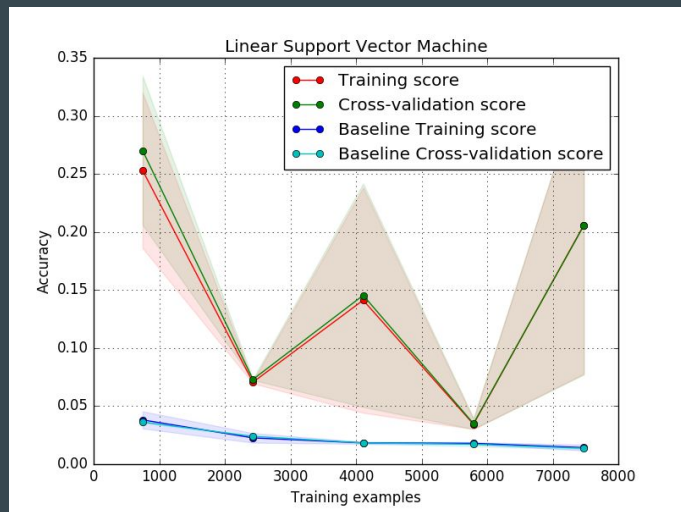
# Demo





# Step 1: Learning curves



# Step 1: Learning curves




# Step 1: Learning curves







# Step 2: CTU dataset




# Step 2: CTU dataset



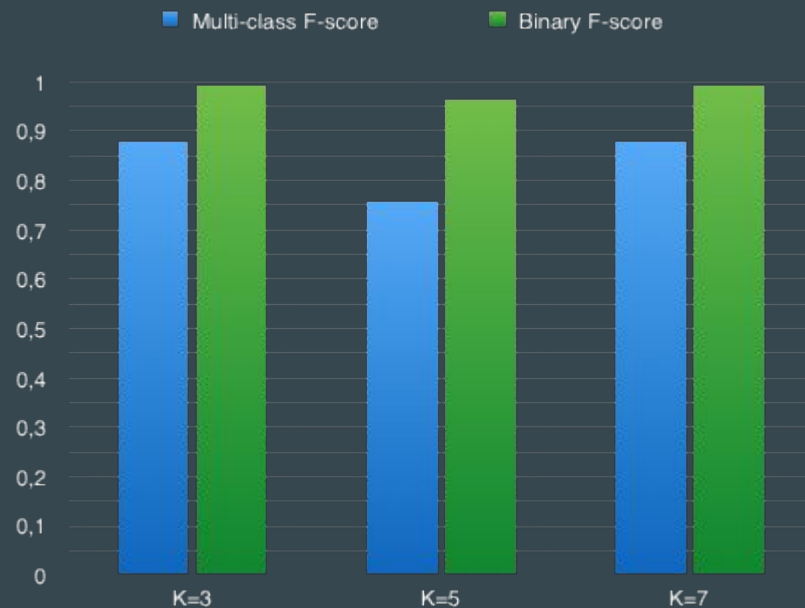
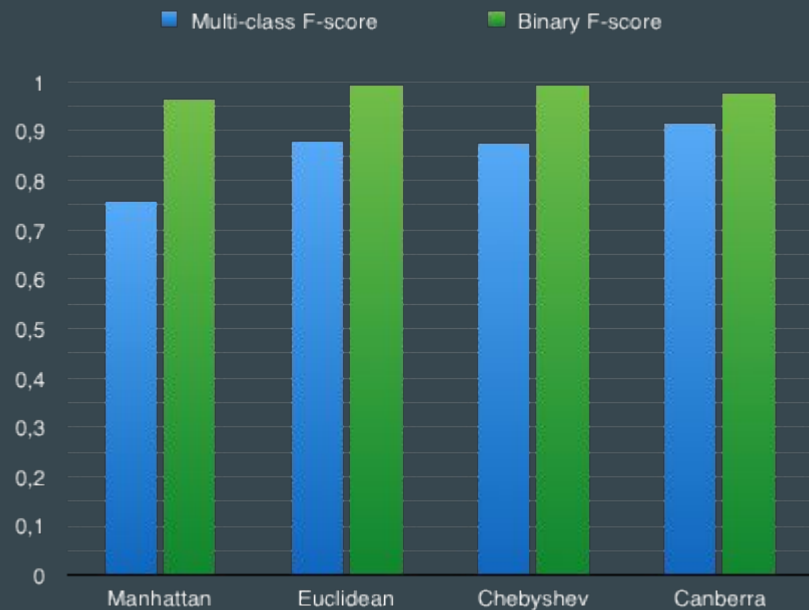
# Step 3: Cross dataset



# Step 3: Cross dataset



# Step 3: K-nearest neighbors



# Stap 4: real-world testing

	K-Nearest Neighbours	Decision tree classifier
F-score	0,7633	0,0155

**Vragen?**

---

# Doelstelling ID systemen

Classificeren/detectie van onverwacht netwerkgedrag

Extern:

port scans

ssh connection attempts

side-effect verkeer (ICMP, IRC)

high volume DDoS

low volume DDoS

Intern:

botnets (communication with  
master/assist with DDoS  
attacks)

worms (bij  
binnendringen/uitbreken van  
systeem)



# Typische werking van bestaande ID systemen

Veel voorkomende technieken:

Signature-based detecties (op basis van rule matching op inhoud van flow/packet data)

Anomaly detection

Algemene doelstelling : patroonherkenning

Binaire classificatie: malicious vs non-malicious

Classificatie voor specifieke type van malicious behaviour

---

# Specifieke eigenschappen v.h. te ontwikkelen systeem

Detectie louter gebaseerd op flow data:

- i.t.t packet- en log-based ID systemen

- specifiek bedoeld voor high traffic systems

- vereist geen in-depth knowledge van het netwerk

Gebruik van machine learning technieken

- Kosten-efficiënt inzetten in bestaande netwerken

- Algoritmes 'leren' zelf zonder regeltjes expliciet te programmeren

---

# De onderzoeksvragen van de bachelorproef

In hoeverre zijn machine learning technieken inzetbaar voor anomaly detection (welke technieken werken goed/niet goed) ?

Hoe kan flow data gebruikt worden in deze technieken?

Kunnen we een IDS maken dat out-of-the-box een aanvaardbare 'hit rate' biedt ?

Welke types anomalie kunnen we automatisch detecteren ?

Is (automatische) klassificatie van de anomalie mogelijk ?

Zijn dergelijke technieken bruikbaar in real-life condities ?

---

# Training data

Geannoteerde data sets zijn specifiek bedoeld om het algoritme een model aan te leren (stap 1 en 2)

worden typisch opgedeeld in disjuncte subsets

1 subset specifiek om een model aan te leren

1 subset om dit model te kunnen valideren

---

# Momenteel gebruikte datasets

CTU-13 dataset (stappen 1, 2 en 3):

- Bevat botnet, normaal en background traffic

- Zeer gedetailleerd geclassificeerd

Tracelabel dataset van UTwente (stappen 1, 2 en 3):

- Bevat traffic geclassificeerd als malicious door honeypot

- Bevat ftp, http, ssh, icmp, irc verkeer

EDM dataverkeer (stap 4):

- Unlabeled data

- Manuele verificatie van classificatie

---